



**ΠΑΝΕΠΙΣΤΗΜΙΟ
ΔΥΤΙΚΗΣ ΑΤΤΙΚΗΣ**
UNIVERSITY OF WEST ATTICA

**ΠΑΝΕΠΙΣΤΗΜΙΟ ΔΥΤΙΚΗΣ ΑΤΤΙΚΗΣ
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ
ΚΑΙ ΥΠΟΛΟΓΙΣΤΩΝ**

ΔΙΑΧΕΙΡΙΣΗ ΔΕΔΟΜΕΝΩΝ ΜΕΓΑΛΗΣ ΚΑΤΜΑΚΑΣ

ΌΝΟΜΑ ΔΙΔΑΣΚΟΝΤΑ: ΠΑΝΑΓΙΩΤΗΣ ΑΡΓΥΡΑΚΗΣ

ΟΝΟΜΑΤΕΠΩΝΥΜΟ: ΔΗΜΗΤΡΙΟΣ ΝΟΜΙΚΟΣ

ΑΡΙΘΜΟΣ ΜΗΤΡΩΟΥ: 22390160

8ο ΕΞΑΜΗΝΟ , 7/6/2026

**REPORT : ΕΦΑΡΜΟΓΗ ΤΕΧΝΙΚΩΝ DATA MINING
ΓΙΑ ΤΗΝ ΠΡΟΒΛΕΨΗ ΚΑΡΔΙΑΚΗΣ ΝΟΣΟΥ**

Πίνακας Περιεχομένων

1. Εισαγωγή	3
2. Περιγραφή Dataset	3
a. 2.1 Heart Disease Dataset	3
b. 2.2 Περιγραφή Χαρακτηριστικών	3
3. Data Preprocessing	4
a. 3.1 Φόρτωση Δεδομένων	4
b. 3.2 Έλεγχος Ελλιπών Τιμών	4
c. 3.3 Ανίχνευση και Αφαίρεση Διπλότυπων Εγγραφών	4
d. 3.4 Διαχωρισμός Training και Test Set	5
e. 3.5 Κανονικοποίηση Δεδομένων	5
f. 3.6 Έλεγχος Ακραίων Τιμών (Outliers)	5
g. 3.7 Feature Engineering	6
4. Exploratory Data Analysis (EDA)	7
a. 4.1 Κατανομή Μεταβλητής Στόχου	7
b. 4.2 Κατανομή Ηλικίας	8
c. 4.3 Κατανομή Χοληστερόλης	8
d. 4.4 Correlation Analysis	8
5. Classification Models	10
a. 5.1 Logistic Regression	10
b. 5.2 Decision Tree	12
6. Advanced Technique – K-Means Clustering	13
7. Evaluation and Comparison	14
8. Συμπεράσματα	15
9. Βιβλιογραφία	16

1. Εισαγωγή

Η εξόρυξη γνώσης από δεδομένα (Data Mining) αποτελεί ένα σημαντικό πεδίο της επιστήμης των δεδομένων, καθώς επιτρέπει την ανακάλυψη χρήσιμων προτύπων και σχέσεων μέσα από μεγάλα σύνολα δεδομένων. Τα τελευταία χρόνια η χρήση τεχνικών μηχανικής μάθησης έχει επεκταθεί σημαντικά στον τομέα της υγείας, όπου μπορεί να συμβάλει στην υποστήριξη της λήψης αποφάσεων και στην πρόβλεψη ασθενειών.

Σκοπός της παρούσας εργασίας είναι η ανάλυση ενός συνόλου δεδομένων που σχετίζεται με καρδιακές παθήσεις και η εφαρμογή τεχνικών ταξινόμησης για την πρόβλεψη της ύπαρξης καρδιακής νόσου. Επιπλέον, πραγματοποιείται διερευνητική ανάλυση δεδομένων (EDA), αξιολόγηση μοντέλων και εφαρμογή τεχνικής ομαδοποίησης (clustering).

Για την υλοποίηση της εργασίας χρησιμοποιήθηκαν οι βιβλιοθήκες Pandas, Scikit-Learn, Matplotlib και Seaborn σε περιβάλλον Google Colab.

2. Περιγραφή Dataset

2.1 Heart Disease Dataset

Για την εργασία χρησιμοποιήθηκε το Heart Disease Dataset από την πλατφόρμα Kaggle. Το συγκεκριμένο dataset περιλαμβάνει ιατρικά χαρακτηριστικά ασθενών τα οποία σχετίζονται με την πιθανότητα εμφάνισης καρδιακής νόσου.

Η μεταβλητή στόχος (target) παίρνει δύο τιμές:

- 0 : Δεν υπάρχει καρδιακή νόσος
- 1 : Υπάρχει καρδιακή νόσος

Στόχος των μοντέλων είναι να προβλέψουν σωστά την τιμή της μεταβλητής target με βάση τα υπόλοιπα χαρακτηριστικά.

2.2 Περιγραφή Χαρακτηριστικών

Τα βασικά χαρακτηριστικά του dataset είναι:

Χαρακτηριστικό	Περιγραφή
age	Ηλικία ασθενούς
sex	Φύλο
cp	Τύπος θωρακικού πόνου

trestbps	Αρτηριακή πίεση ηρεμίας
chol	Επίπεδα χοληστερόλης
fbs	Σάκχαρο αίματος νηστείας
restecg	Αποτελέσματα ηλεκτροκαρδιογραφήματος
thalach	Μέγιστος καρδιακός ρυθμός
exang	Στηθάγχη κατά την άσκηση
oldpeak	Κατάθλιψη ST
slope	Κλίση τμήματος ST
ca	Αριθμός μεγάλων αγγείων
thal	Αποτέλεσμα εξέτασης θαλασσαιμίας
target	Μεταβλητή στόχος

3. Data Preprocessing

Η προεπεξεργασία των δεδομένων αποτελεί σημαντικό στάδιο πριν την εκπαίδευση των μοντέλων, καθώς εξασφαλίζει καλύτερη ποιότητα δεδομένων και πιο αξιόπιστα αποτελέσματα.

3.1 Φόρτωση και Έλεγχος Δεδομένων

Αρχικά το dataset φορτώθηκε στο περιβάλλον Google Colab με χρήση της βιβλιοθήκης Pandas. Στη συνέχεια πραγματοποιήθηκε έλεγχος της δομής του dataset και των τύπων δεδομένων κάθε χαρακτηριστικού.

Το αρχικό σύνολο δεδομένων περιείχε 1025 εγγραφές και 14 χαρακτηριστικά.

3.2 Έλεγχος Ελλιπών Τιμών

Πραγματοποιήθηκε έλεγχος για ελλιπείς τιμές (missing values) σε όλα τα χαρακτηριστικά.

Από τα αποτελέσματα διαπιστώθηκε ότι δεν υπήρχαν κενές τιμές στο dataset. Επομένως δεν χρειάστηκε κάποια διαδικασία συμπλήρωσης ή διαγραφής εγγραφών.

3.3 Έλεγχος Διπλότυπων Εγγραφών

Στη συνέχεια πραγματοποιήθηκε έλεγχος για διπλότυπες εγγραφές.

Κατά τον έλεγχο εντοπίστηκαν συνολικά 723 διπλότυπες εγγραφές. Η ύπαρξη τόσο μεγάλου αριθμού διπλότυπων μπορεί να επηρεάσει την εκπαίδευση των μοντέλων, καθώς αυξάνει τεχνητά τη συχνότητα ορισμένων παρατηρήσεων.

Για τον λόγο αυτό οι διπλότυπες εγγραφές αφαιρέθηκαν.

Μετά την αφαίρεση των διπλότυπων το dataset περιλάμβανε 302 μοναδικές εγγραφές και 14 χαρακτηριστικά.

3.4 Διαχωρισμός Δεδομένων

Για την εκπαίδευση και αξιολόγηση των μοντέλων χρησιμοποιήθηκε διαχωρισμός των δεδομένων σε σύνολο εκπαίδευσης και σύνολο ελέγχου.

Συγκεκριμένα:

- 80% των δεδομένων χρησιμοποιήθηκε για εκπαίδευση
- 20% των δεδομένων χρησιμοποιήθηκε για έλεγχο

Με τον τρόπο αυτό τα μοντέλα αξιολογήθηκαν σε δεδομένα που δεν είχαν χρησιμοποιηθεί κατά την εκπαίδευσή τους.

3.5 Κανονικοποίηση Δεδομένων


Για ορισμένους αλγορίθμους μηχανικής μάθησης είναι σημαντικό όλα τα χαρακτηριστικά να βρίσκονται περίπου στην ίδια κλίμακα τιμών.

Για τον λόγο αυτό εφαρμόστηκε StandardScaler, ο οποίος μετατρέπει κάθε χαρακτηριστικό ώστε να έχει μέση τιμή κοντά στο μηδέν και τυπική απόκλιση ίση με ένα.

Η κανονικοποίηση εφαρμόστηκε μόνο στα δεδομένα εκπαίδευσης και στη συνέχεια χρησιμοποιήθηκε στα δεδομένα ελέγχου.

3.6 Έλεγχος Ακραίων Τιμών (Outliers)


Πραγματοποιήθηκε έλεγχος για την ύπαρξη ακραίων τιμών στα βασικά αριθμητικά χαρακτηριστικά του συνόλου δεδομένων με τη χρήση διαγραμμάτων boxplot. Παρατηρήθηκαν ορισμένες ακραίες τιμές κυρίως στα χαρακτηριστικά χοληστερόλης (chol) και oldpeak. Ωστόσο, οι τιμές αυτές θεωρήθηκαν ρεαλιστικές για ιατρικά δεδομένα και δεν αφαιρέθηκαν από το dataset, καθώς ενδέχεται να αντιπροσωπεύουν πραγματικές περιπτώσεις ασθενών.



Σχήμα 1: Boxplots για τον εντοπισμό ακραίων τιμών στα βασικά αριθμητικά χαρακτηριστικά.

3.7 Feature Engineering

Στο πλαίσιο της βελτίωσης της αναπαράστασης των δεδομένων δημιουργήθηκε νέο χαρακτηριστικό με την ονομασία `age_group`. Το χαρακτηριστικό αυτό προέκυψε από την ομαδοποίηση της ηλικίας των ασθενών σε τρεις κατηγορίες: νέοι, μέσης ηλικίας και ηλικιωμένοι. Η διαδικασία αυτή επιτρέπει την ευκολότερη ανάλυση της ηλικιακής κατανομής και αποτελεί παράδειγμα τεχνικής *feature engineering*.



Σχήμα 2: Κατανομή των ηλικιακών ομάδων που προέκυψαν από το νέο χαρακτηριστικό `age_group`.


4. Exploratory Data Analysis (EDA)

Μετά την ολοκλήρωση της προεπεξεργασίας πραγματοποιήθηκε εξερευνητική ανάλυση δεδομένων (Exploratory Data Analysis – EDA), με σκοπό την καλύτερη κατανόηση των χαρακτηριστικών του dataset και τον εντοπισμό πιθανών σχέσεων μεταξύ των μεταβλητών.

Η διαδικασία αυτή είναι ιδιαίτερα σημαντική, καθώς επιτρέπει την εξαγωγή χρήσιμων συμπερασμάτων πριν την εφαρμογή των αλγορίθμων μηχανικής μάθησης.

4.1 Κατανομή της Μεταβλητής Στόχου

Αρχικά εξετάστηκε η κατανομή της μεταβλητής στόχου (`target`), η οποία δείχνει εάν ένας ασθενής παρουσιάζει καρδιακή νόσο ή όχι.



Σχήμα 3: Κατανομή της μεταβλητής στόχου, της ηλικίας και της χοληστερόλης των ασθενών.

Από το διάγραμμα παρατηρείται ότι οι δύο κατηγορίες εμφανίζονται σε παρόμοιες συχνότητες. Αυτό είναι θετικό για την εκπαίδευση των μοντέλων, καθώς αποφεύγονται προβλήματα που σχετίζονται με έντονα μη ισορροπημένα δεδομένα.

4.2 Κατανομή Ηλικίας

Στο δεύτερο διάγραμμα εξετάστηκε η κατανομή της ηλικίας των ασθενών.

Παρατηρείται ότι οι περισσότερες εγγραφές αφορούν άτομα ηλικίας μεταξύ 45 και 65 ετών. Η μέση ηλικία των ασθενών βρίσκεται περίπου στα 54 έτη, γεγονός που συμφωνεί με τα ευρήματα της βιβλιογραφίας σχετικά με τις καρδιαγγειακές παθήσεις.


4.3 Κατανομή Χοληστερόλης

Το τρίτο διάγραμμα παρουσιάζει την κατανομή των επιπέδων χοληστερόλης.

Οι περισσότερες τιμές συγκεντρώνονται μεταξύ 200 και 300 mg/dL, ενώ εμφανίζονται και ορισμένες ακραίες τιμές. Η ύπαρξη υψηλών τιμών χοληστερόλης είναι αναμενόμενη, καθώς πρόκειται για χαρακτηριστικό που σχετίζεται άμεσα με καρδιαγγειακά προβλήματα.

4.4 Ανάλυση Συσχετίσεων

Για τη διερεύνηση των σχέσεων μεταξύ των χαρακτηριστικών υπολογίστηκε ο πίνακας συσχέτισης (Correlation Matrix) και παρουσιάστηκε με τη μορφή Heatmap.



Σχήμα 4: Correlation Heatmap των χαρακτηριστικών του dataset.

Από το Heatmap προκύπτει ότι ορισμένα χαρακτηριστικά παρουσιάζουν ισχυρότερη συσχέτιση με την παρουσία καρδιακής νόσου.

Θετική συσχέτιση εμφανίζουν κυρίως:

- cp (τύπος θωρακικού πόνου)
- thalach (μέγιστος καρδιακός ρυθμός)
- slope

Αντίθετα, αρνητική συσχέτιση παρουσιάζουν:

- exang
- oldpeak
- ca
- thal

Τα αποτελέσματα αυτά υποδηλώνουν ότι τα συγκεκριμένα χαρακτηριστικά μπορούν να συμβάλουν σημαντικά στην πρόβλεψη της καρδιακής νόσου.

5. Classification Models

Μετά την ολοκλήρωση της ανάλυσης δεδομένων ακολούθησε η εφαρμογή αλγορίθμων ταξινόμησης με στόχο την πρόβλεψη της μεταβλητής target.

Για την εργασία επιλέχθηκαν δύο διαφορετικοί αλγόριθμοι:

- Logistic Regression
- Decision Tree

Η χρήση δύο διαφορετικών μοντέλων επιτρέπει τη σύγκριση της απόδοσής τους και την επιλογή της καταλληλότερης προσέγγισης για το συγκεκριμένο πρόβλημα.

5.1 Logistic Regression


Η Logistic Regression αποτελεί έναν από τους πιο διαδεδομένους αλγορίθμους δυαδικής ταξινόμησης και χρησιμοποιείται ευρέως σε προβλήματα πρόβλεψης κατηγοριών.

Το μοντέλο εκπαιδεύτηκε χρησιμοποιώντας τα κανονικοποιημένα δεδομένα εκπαίδευσης και στη συνέχεια αξιολογήθηκε στο σύνολο ελέγχου.

Τα αποτελέσματα που προέκυψαν ήταν:


- Accuracy: 77.05%
- Precision: 0.70
- Recall: 0.90
- F1-Score: 0.79

Το υψηλό Recall δείχνει ότι το μοντέλο κατάφερε να εντοπίσει με επιτυχία το μεγαλύτερο ποσοστό των ασθενών που εμφανίζουν καρδιακή νόσο.



Σχήμα 5: Confusion Matrix της Logistic Regression.

Παρατηρείται ότι το μοντέλο ταξινόμησε σωστά το μεγαλύτερο μέρος των περιπτώσεων και ιδιαίτερα των ασθενών που παρουσίαζαν καρδιακή νόσο.



Σχήμα 6: ROC Curve της Logistic Regression.

Η καμπύλη ROC παρουσίασε τιμή AUC ίση με 0.83, γεγονός που υποδηλώνει καλή διαχωριστική ικανότητα μεταξύ των δύο κατηγοριών.

5.2 Decision Tree


Ο αλγόριθμος Decision Tree βασίζεται στη δημιουργία ενός δέντρου αποφάσεων, στο οποίο κάθε κόμβος αντιστοιχεί σε έναν κανόνα διαχωρισμού των δεδομένων.

Το μοντέλο εκπαιδεύτηκε χρησιμοποιώντας τα δεδομένα εκπαίδευσης και στη συνέχεια αξιολογήθηκε στο σύνολο ελέγχου.

Τα αποτελέσματα που προέκυψαν ήταν:

- Accuracy: 73.77%
- Precision: 0.74
- Recall: 0.69
- F1-Score: 0.71

Παρότι το μοντέλο παρουσίασε ικανοποιητική απόδοση, τα αποτελέσματά του ήταν χαμηλότερα σε σχέση με τη Logistic Regression.



Σχήμα 7: Confusion Matrix του Decision Tree.

Από τον πίνακα σύγχυσης παρατηρείται ότι το μοντέλο πραγματοποίησε περισσότερα λανθασμένα classifications σε σχέση με τη Logistic Regression, γεγονός που εξηγεί και τη χαμηλότερη συνολική απόδοσή του.


6. Advanced Technique – K-Means Clustering

Εκτός από τα μοντέλα ταξινόμησης, εφαρμόστηκε και μία τεχνική μη επιβλεπόμενης μάθησης (Unsupervised Learning), συγκεκριμένα ο αλγόριθμος K-Means Clustering.

Στόχος του αλγορίθμου είναι η ομαδοποίηση των δεδομένων σε ομάδες (clusters) με βάση τα κοινά χαρακτηριστικά τους, χωρίς να χρησιμοποιείται η μεταβλητή στόχος.

Για την παρούσα εργασία επιλέχθηκε η δημιουργία δύο clusters ($k = 2$), καθώς η μεταβλητή στόχος διαχωρίζει τους ασθενείς σε δύο βασικές κατηγορίες: ασθενείς με καρδιακή νόσο και ασθενείς χωρίς καρδιακή νόσο.

Μετά την εκτέλεση του αλγορίθμου πραγματοποιήθηκε μείωση διαστάσεων με τη μέθοδο Principal Component Analysis (PCA), ώστε τα αποτελέσματα να μπορούν να απεικονιστούν σε δύο διαστάσεις.



Σχήμα 8: Οπτικοποίηση των clusters με χρήση PCA.

Από το διάγραμμα παρατηρείται ότι τα δεδομένα χωρίζονται σε δύο κύριες ομάδες. Ωστόσο, υπάρχει σημαντική επικάλυψη μεταξύ των clusters, γεγονός που δείχνει ότι τα χαρακτηριστικά των ασθενών δεν επιτρέπουν έναν πλήρως καθαρό διαχωρισμό.

Για την αξιολόγηση της ποιότητας των clusters χρησιμοποιήθηκε ο δείκτης Silhouette Score.

Το αποτέλεσμα που προέκυψε ήταν:

Silhouette Score = 0.18

Η συγκεκριμένη τιμή υποδηλώνει σχετικά αδύναμο διαχωρισμό μεταξύ των ομάδων. Παρόλα αυτά, το αποτέλεσμα θεωρείται αναμενόμενο για ιατρικά δεδομένα, όπου συχνά υπάρχουν κοινά χαρακτηριστικά μεταξύ διαφορετικών κατηγοριών ασθενών.

7. Evaluation and Comparison of Models

Στο κεφάλαιο αυτό πραγματοποιείται η συνολική αξιολόγηση και σύγκριση των μοντέλων που εφαρμόστηκαν.

Η αξιολόγηση βασίστηκε στις μετρικές Accuracy, Precision, Recall και F1-Score.

Τα αποτελέσματα παρουσιάζονται στον παρακάτω πίνακα.

Metric	Logistic Regression	Decision Tree
Accuracy	77.05%	73.77%
Precision	0.70	0.74
Recall	0.90	0.69
F1-Score	0.79	0.71

Παρατηρείται ότι η Logistic Regression πέτυχε υψηλότερη ακρίβεια (Accuracy) σε σχέση με το Decision Tree.

Ιδιαίτερα σημαντικό είναι το Recall, το οποίο στην περίπτωση της Logistic Regression έφτασε το 90%. Αυτό σημαίνει ότι το μοντέλο κατάφερε να εντοπίσει το μεγαλύτερο ποσοστό των ασθενών που εμφάνιζαν καρδιακή νόσο.

Αντίθετα, το Decision Tree εμφάνισε χαμηλότερο Recall, γεγονός που σημαίνει ότι απέτυχε να αναγνωρίσει περισσότερες πραγματικές περιπτώσεις ασθενών.

Στον τομέα της υγείας η σωστή αναγνώριση των ασθενών θεωρείται ιδιαίτερα σημαντική, επομένως το Recall αποτελεί μία από τις πιο κρίσιμες μετρικές αξιολόγησης.

Με βάση τα αποτελέσματα των πειραμάτων, η Logistic Regression παρουσίασε συνολικά καλύτερη απόδοση και θεωρείται η καταλληλότερη επιλογή για το συγκεκριμένο dataset.

8. Συμπεράσματα

Σκοπός της παρούσας εργασίας ήταν η εφαρμογή τεχνικών εξόρυξης δεδομένων και μηχανικής μάθησης για την πρόβλεψη καρδιακής νόσου.

Αρχικά πραγματοποιήθηκε προεπεξεργασία του Heart Disease Dataset, κατά την οποία εντοπίστηκαν και αφαιρέθηκαν 723 διπλότυπες εγγραφές. Μετά τον καθαρισμό των δεδομένων το τελικό dataset περιλάμβανε 302 μοναδικές εγγραφές.

Στη συνέχεια πραγματοποιήθηκε εξερευνητική ανάλυση δεδομένων, η οποία βοήθησε στην καλύτερη κατανόηση των χαρακτηριστικών του συνόλου δεδομένων και στην αναγνώριση σημαντικών σχέσεων μεταξύ των μεταβλητών.

Για την πρόβλεψη της καρδιακής νόσου εφαρμόστηκαν δύο μοντέλα ταξινόμησης, η Logistic Regression και το Decision Tree. Η αξιολόγηση έδειξε ότι η Logistic Regression παρουσίασε καλύτερα αποτελέσματα σε σχέση με το Decision Tree, επιτυγχάνοντας Accuracy 77.05% και Recall 90%.

Επιπλέον εφαρμόστηκε ο αλγόριθμος K-Means Clustering για την ομαδοποίηση των δεδομένων. Τα αποτελέσματα έδειξαν ότι είναι δυνατός ο διαχωρισμός των ασθενών σε δύο βασικές ομάδες, αν και με σημαντική επικάλυψη μεταξύ τους.

Συνολικά, τα αποτελέσματα της εργασίας δείχνουν ότι οι τεχνικές Data Mining μπορούν να αξιοποιηθούν αποτελεσματικά για την υποστήριξη εφαρμογών στον χώρο της υγείας και για την πρόβλεψη της πιθανότητας εμφάνισης καρδιακής νόσου.

Λόγω του μικρού μεγέθους του συνόλου δεδομένων δεν κρίθηκε απαραίτητη η χρήση τεχνολογιών Big Data, όπως Apache Spark ή MapReduce. Οι συγκεκριμένες τεχνολογίες χρησιμοποιούνται κυρίως σε περιπτώσεις πολύ μεγάλων συνόλων δεδομένων, όπου οι κλασικές μέθοδοι επεξεργασίας δεν επαρκούν. Ωστόσο, σε μελλοντική εφαρμογή της μεθοδολογίας σε μεγαλύτερα ιατρικά datasets θα μπορούσε να αξιοποιηθεί ένα κατακευματισμένο περιβάλλον επεξεργασίας δεδομένων για ταχύτερη εκπαίδευση και ανάλυση.

9. Βιβλιογραφία

[1] Heart Disease Dataset, Kaggle.

[2] Pedregosa F., Varoquaux G., Gramfort A. et al., "Scikit-learn: Machine Learning in Python", Journal of Machine Learning Research, 2011.

[3] Pandas Documentation, <https://pandas.pydata.org>

[4] Matplotlib Documentation, <https://matplotlib.org>

[5] Seaborn Documentation, <https://seaborn.pydata.org>